

Automatyczne wykrywanie liczby klastrow w danych

Porównanie metod elbow, silhouette score i gap statistic na zbiorze danych kart kredytowych

Patryk Cwajna, Bruno Howaniec, Kamil Dwornik¹

¹Wydział Informatyki / Eksploracja i wizualizacja danych

June 14, 2026

Abstract

Celem pracy było zbadanie skuteczności metod automatycznego wyznaczania optymalnej liczby klastrow – elbow method, silhouette score i gap statistic – w kontekście segmentacji klientów instytucji finansowej. Przeprowadzono analizę zbioru danych *Credit Card Dataset for Clustering* (CC General, Kaggle), zawierającego 8950 obserwacji i 17 zmiennych numerycznych opisujących zachowania zakupowe posiadaczy kart kredytowych. Wykonano preprocessing danych (imputacja, inżynieria cech, transformacja logarytmiczna, standaryzacja), eksploracyjną analizę danych oraz redukcję wymiarowości (PCA, t-SNE). Porównano trzy algorytmy klasteryzacji: K-Means, klasteryzację hierarchiczną oraz DBSCAN, oceniając je metrykami Silhouette Score oraz indeksem Daviesa-Bouldina. Uzyskane wyniki wskazują, że K-Means z $k=4$ klastrami osiągnął najlepszą zwartość klastrow (Silhouette = 0.3621, DBI = 1.1591), a dane pozwoliły wyróżnić cztery interpretowalne segmenty klientów.

Słowa kluczowe: klasteryzacja, K-Means, DBSCAN, elbow method, silhouette score, gap statistic, segmentacja klientów, karty kredytowe

1. Wprowadzenie

Klasteryzacja danych należy do fundamentalnych zadań eksploracji danych, umożliwiając odkrywanie ukrytych struktur w zbiorach bez etykiet klas. W praktycznych zastosowaniach – takich jak segmentacja klientów, wykrywanie anomalii czy analiza rynkowa – kluczowym wyzwaniem jest dobór optymalnej liczby klastrow, ponieważ większość algorytmów (w szczególności K-Means) wymaga jej podania z góry.

Celem niniejszego projektu jest porównanie metod wyznaczania optymalnej liczby klastrow:

- **elbow method** – analiza zmiany inercji (WCSS) w funkcji liczby klastrow,
- **silhouette score** – miara jakości separacji klastrow,
- **gap statistic** – porównanie inercji z inercją losowego rozkładu danych.

Dodatkowo uwzględniono DBSCAN jako metodę automatycznie wyznaczającą liczbę klastrów na podstawie struktury gęstościowej danych.

Główne pytania badawcze:

1. Która z metod (elbow, silhouette, gap statistic) najskuteczniej wskazuje optymalną liczbę klastrów dla danych finansowych?
2. Czy algorytmy klasteryzacji oparte na różnych założeniach (K-Means, Hierarchical, DBSCAN) dają spójne wyniki na tym samym zbiorze?
3. Czy wykryte klastry mają czytelną interpretację biznesową w kontekście segmentacji klientów?

2. Opis danych

2.1. Źródło danych

W projekcie wykorzystano zbiór danych *Credit Card Dataset for Clustering* (CC General), udostępniony publicznie w serwisie Kaggle (<https://www.kaggle.com/datasets/arjunbhasin2013/ccdata>). Zbiór zawiera informacje o zachowaniach zakupowych 8950 posiadaczy kart kredytowych zebranych przez pewną instytucję finansową.

2.2. Charakterystyka zbioru

Zbiór danych zawiera:

- liczbę obserwacji: **8950**,
- liczbę cech: **18** (17 numerycznych + 1 identyfikator klienta CUST_ID),
- typy zmiennych: numeryczne (float64, int64).

Table 1: Opis wybranych zmiennych zbioru CC General

Zmienna	Typ	Opis
BALANCE	float64	Bieżące saldo na koncie
PURCHASES	float64	Łączna kwota zakupów
ONEOFF_PURCHASES	float64	Kwota zakupów jednorazowych
INSTALLMENTS_PURCHASES	float64	Kwota zakupów ratałnych
CASH_ADVANCE	float64	Kwota wypłat gotówkowych
CREDIT_LIMIT	float64	Limit kredytowy
PAYMENTS	float64	Łączna kwota spłat
MINIMUM_PAYMENTS	float64	Minimalne wymagane spłaty
PRC_FULL_PAYMENT	float64	Procent pełnych spłat
TENURE	int64	Czas korzystania z karty (mies.)

W zbiorze danych stwierdzono brakujące wartości w kolumnach: `MINIMUM_PAYMENTS` (313 braków, 3,5%) oraz `CREDIT_LIMIT` (1 brak). Kolumna `CUST_ID` została usunięta jako identyfikator nieistotny analitycznie.

3. Metodologia

3.1. Przygotowanie danych

W etapie preprocessingu wykonano następujące operacje:

- **Imputacja braków:** ze względu na prawoskośny rozkład zmiennych finansowych zastosowano medianę dla `MINIMUM_PAYMENTS` i `CREDIT_LIMIT`,
- **Usunięcie duplikatów:** weryfikacja profilaktyczna (stwierdzono 0 duplikatów),
- **Inżynieria cech:** utworzono nowe zmienne biznesowe: `MONTHLY_PURCHASES` (zakupy/`TENURE`), `MONTHLY_CASH_ADVANCE` (gotówka/`TENURE`), `LIMIT_USAGE_RATE` (`BALANCE`/`CREDIT_LIMIT`) oraz kategorię zmienną `PURCHASE_TYPE` (None, One-Off, Installment, Both),
- **Kodowanie:** one-hot encoding zmiennej `PURCHASE_TYPE`,
- **Transformacja logarytmiczna:** `log1p` dla wszystkich silnie prawoskośnych zmiennych numerycznych,
- **Standaryzacja:** `StandardScaler` – doprowadzenie do rozkładu o średniej 0 i odchyleniu 1.

Po preprocessingu ostateczny zbiór zawierał 8950 obserwacji i 23 cechy. Efekt transformacji przedstawia rysunek 1.




Figure 1: Rozkład zmiennej MONTHLY_CASH_ADVANCE przed (lewy) i po (prawy) transformacji logarytmicznej i standaryzacji

3.2. Eksploracyjna analiza danych

W ramach EDA przeprowadzono:

- analizę statystyk opisowych (mean, std, min/max, kwartyle),
- analizę rozkładów zmiennych – histogramy i boxploty,
- badanie korelacji – macierz korelacji (wysoka korelacja PURCHASES i ONEOFF_PURCHASES: $r = 0.92$),
- wizualizację zależności PURCHASES vs PAYMENTS (scatter plot),
- analizę warunkową: rozkład LIMIT_USAGE_RATE według PURCHASE_TYPE,
- identyfikację anomalii metodą Isolation Forest.

3.3. Redukcja wymiarowości

Zastosowano dwie metody:

- **PCA** (Principal Component Analysis): analiza skumulowanej wariancji wykazała, że 6 głównych składowych wyjaśnia 80% wariancji danych (9 składowych – 90%). Do modelowania użyto 6 składowych.
- **t-SNE**: redukcja do 2 wymiarów wyłącznie do celów wizualizacji nieliniowych struktur (perplexity=30).

3.4. Zastosowane metody klasteryzacji

W pracy porównano trzy metody:

- **K-Means**: iteracyjny algorytm minimalizujący inercję (WCSS). Do wyznaczenia optymalnego k zastosowano elbow method, silhouette score oraz gap statistic dla $k \in \{2, \dots, 10\}$.
- **Agglomerative Hierarchical Clustering**: aglomeracyjna klasteryzacja hierarchiczna z oceną silhouette score dla $k \in \{2, \dots, 10\}$.
- **DBSCAN**: algorytm oparty na gęstości, automatycznie wyznaczający liczbę klastrów. Optymalizowano parametr $\varepsilon \in [1.5, 3.5]$ przy `min_samples=46`.

3.5. Metody oceny

Do porównania algorytmów zastosowano:

- **Silhouette Score** – mierzy, jak dobrze każda obserwacja pasuje do swojego klastra w stosunku do sąsiednich klastrów; wartości w $[-1, 1]$, wyższe = lepsze,
- **Davies-Bouldin Index (DBI)** – stosunek rozproszenia wewnątrzklasowego do separacji między klastrami; niższe = lepsze (minimum: 0).

4. Eksploracyjna analiza danych

4.1. Statystyki opisowe

Zmienne finansowe w zbiorze wykazują silną prawostronną skośność – typową dla danych transakcyjnych, gdzie większość klientów generuje umiarkowane wartości, ale nieliczni klienci osiągają wartości skrajnie wysokie.

Table 2: Wybrane statystyki opisowe (dane oryginalne, przed transformacją)

Zmienna	Średnia	Odch. std.	Min	Max
BALANCE	1564.47	2081.53	0.00	19043.14
PURCHASES	1003.20	2136.63	0.00	49039.57
CASH_ADVANCE	978.87	2097.16	0.00	47137.21
CREDIT_LIMIT	4494.45	3638.82	50.00	30000.00
PAYMENTS	1733.14	2895.06	0.00	50721.48
MINIMUM_PAYMENTS	864.21	2372.45	0.02	76406.21
PRC_FULL_PAYMENT	0.154	0.292	0.00	1.00
TENURE	11.52	1.34	6	12

4.2. Wizualizacja rozkładów

Histogramy zmiennych numerycznych (rysunek 2) ujawniły silną prawostronną skośność wszystkich zmiennych kwotowych. Zmienna TENURE jest quasi-dyskretna – dominuje wartość 12

miesiący.




Figure 2: Histogramy wszystkich zmiennych numerycznych zbioru CC General

Boxploty (rysunek 3) potwierdziły obecność licznych wartości odstających we wszystkich zmiennych finansowych – są one naturalnym elementem danych kart kredytowych i nie zostały usunięte.




Figure 3: Wykresy pudełkowe zmiennych numerycznych – identyfikacja wartości odstających

4.3. Analiza zależności

Macierz korelacji (rysunek 4) ujawniła kilka silnych zależności:

- PURCHASES i ONEOFF_PURCHASES: $r = 0.92$ (wysoka redundancja – zmienna PURCHASES usunięta),
- PURCHASES_FREQUENCY i PURCHASES_INSTALLMENTS_FREQUENCY: $r \approx 0.86$,
- CASH_ADVANCE i CASH_ADVANCE_FREQUENCY/TRX: $r \approx 0.63$.

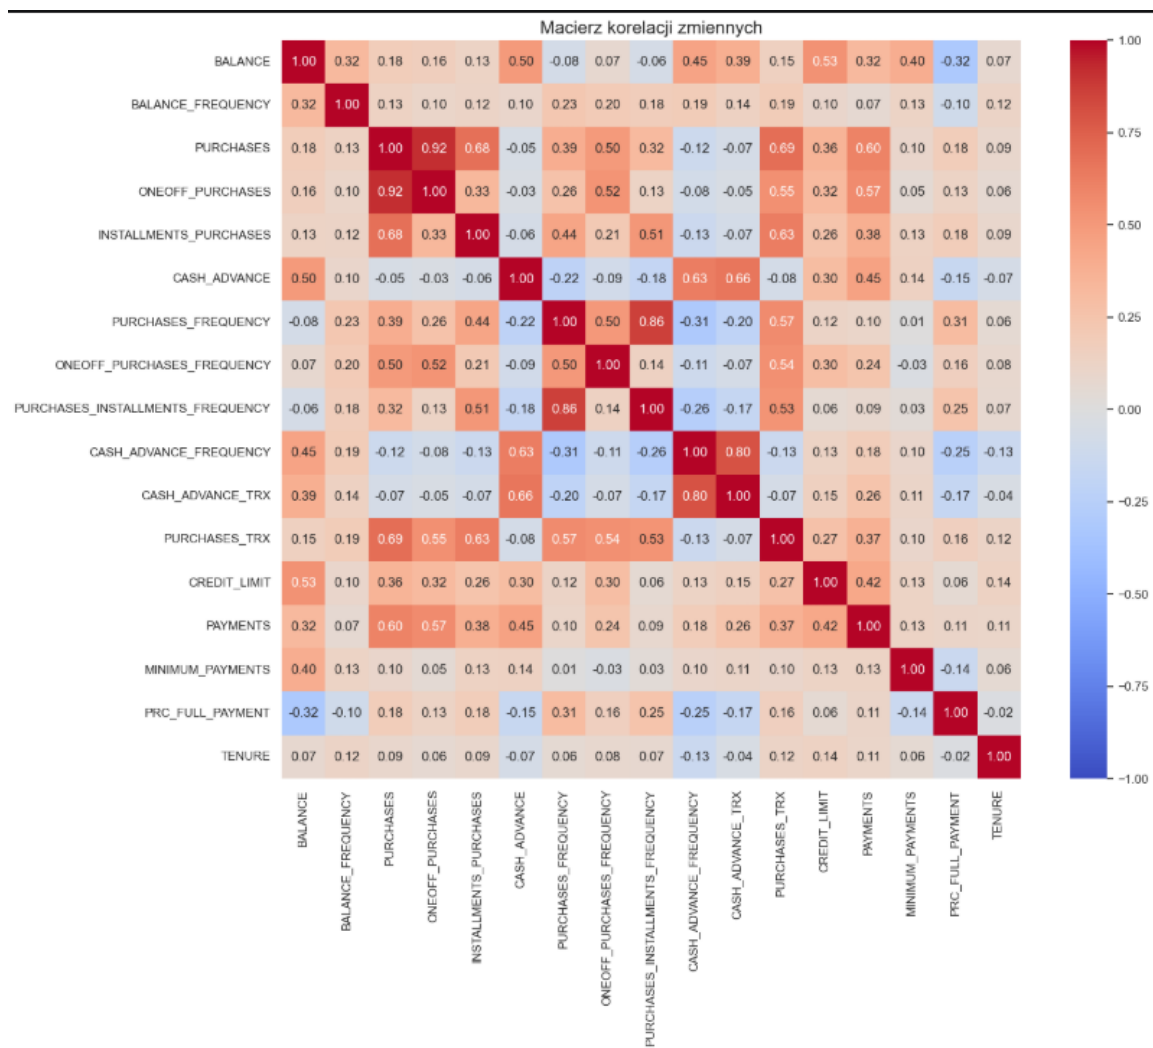


Figure 4: Macierz korelacji zmiennych numerycznych zbioru CC General

Zależność między łączną kwotą zakupów a spłatami (rysunek 5) wskazuje na umiarkowaną korelację liniową z wyraźnymi wartościami odstającymi w obu osiach.




Figure 5: Zależność między łączną kwotą zakupów a spłatami klientów

Analiza warunkowa (rysunek 6) wykazała, że klienci z typem *None* (brak zakupów) cechują się najwyższym stopniem wykorzystania limitu kredytowego, co sugeruje preferowanie gotówkowych wypłat z bankomatu.




Figure 6: Stopień wykorzystania limitu kredytowego według typu zachowań zakupowych

4.4. Identyfikacja anomalii

Do identyfikacji anomalii zastosowano algorytm Isolation Forest. Rysunek 7 przedstawia rozkład punktów normalnych i anomalii w przestrzeni *BALANCE* vs *MONTHLY_PURCHASES*.




Figure 7: Wizualizacja anomalii (Isolation Forest) w przestrzeni BALANCE vs MONTHLY_PURCHASES

5. Eksperymenty i wyniki

5.1. Redukcja wymiarowości PCA

Analiza Scree Plot dla PCA (rysunek 8) wykazała, że pierwszych 6 głównych składowych wyjaśnia 80% wariancji danych oryginalnych (23 cechy po preprocessingu). Wszystkie eksperymenty klasteryzacji przeprowadzono na danych zredukowanych do 6 wymiarów.




Figure 8: Skumulowana wariancja wyjaśniona w funkcji liczby głównych składowych PCA

5.2. Wyznaczanie optymalnej liczby klastrów

Zastosowane metody wskazania optymalnego k dla K-Means:

- **Elbow method:** wyraźne zgięcie krzywej inercji przy $k=4$ (rysunek 9), po którym dalsze zmniejszenie inercji jest marginalne,
- **Silhouette score:** maksimum Silhouette Score dla K-Means osiągnięte przy $k=4$,
- **Gap statistic:** wskazanie wartości k z najwyższą różnicą między inercją danych a inercją losowego punktu referencyjnego – zgodne z $k=4$.




Figure 9: Metoda łokciowa (Elbow Method) – inercja K-Means w funkcji liczby klastrów

Kompleksowe porównanie wszystkich metod przedstawia rysunek 10.




Figure 10: Kompleksowa ocena metod wykrywania liczby klastrów: inercja i gap statistic (K-Means), wskaźnik sylwetki (K-Means vs Hierarchical) oraz DBSCAN w funkcji parametru ε

Wszystkie trzy metody spójnie wskazały $k=4$ jako optymalną liczbę klastrów.

5.3. Porównanie algorytmów klasteryzacji

Table 3: Porównanie metod klasteryzacji dla zbioru CC General

Metoda	Silhouette $\uparrow$	Davies-Bouldin $\downarrow$	Liczba klastrów	Uwagi
K-Means	0.3621	1.1591	4 (zadana)	—
Hierarchical	0.3630	1.1820	4 (zadana)	—
DBSCAN	0.1472	2.0035	2 (auto)	5 pkt szumu

Strzałka $\uparrow$ oznacza, że wyższa wartość jest lepsza; $\downarrow$ – że niższa wartość jest lepsza.

5.4. Wizualizacja klastrów

Rysunek 11 prezentuje wykryte klastry w przestrzeni 2D – zarówno w projekcji PCA, jak i t-SNE. W przestrzeni t-SNE widoczna jest wyraźna separacja czterech grup, co potwierdza sens wyznaczonego podziału.




Figure 11: Wizualizacja wykrytych klastrów K-Means ($k=4$) w przestrzeni PCA 2D (lewy) i t-SNE 2D (prawy)

Heatmapa profilu klastrów (rysunek 12) przedstawia znormalizowane wartości każdej cechy dla poszczególnych segmentów.




Figure 12: Profil klastrów – znormalizowane wartości cech dla każdego segmentu klientów

5.5. Interpretacja modeli – znaczenie zmiennych

Analizę interpretowalności przeprowadzono z wykorzystaniem Feature Importance modelu Random Forest (rysunek 13). Zmienne ONEOFF_PURCHASES oraz INSTALLMENTS_PURCHASES dominują jako predyktory wartości MONTHLY_PURCHASES.




Figure 13: Znaczenie zmiennych (Feature Importance) w modelu Random Forest dla predykcji MONTHLY_PURCHASES

5.6. Charakterystyka wykrytych segmentów

Table 4: Charakterystyka wykrytych segmentów klientów

Klaster	Nazwa	Kluczowe cechy
0	Aktywni na raty	Wysokie INSTALLMENTS_PURCHASES (527), niska gotówka, częste zakupy (freq=0.71), dobry PRC_FULL_PAYMENT (0.27)
1	Użytkownicy gotówki	Najwyższy CASH_ADVANCE (2195), prawie zero zakupów (20), wysoki bilans (2354), niski PRC_FULL_PAYMENT (0.04)
2	Premium Shoppers	Najwyższe PURCHASES (2338), najwyższy limit (5842), aktywni transakcyjnie (34 trx/klient)
3	Jednorazowi kupujący	Prawie wyłącznie ONE-OFF_PURCHASES (819 vs 0 ratalnych), umiarkowany profil ryzyka

6. Dyskusja

Wyniki eksperymentów wskazują na wyraźną przewagę metod wymagających podania liczby klastrów (K-Means, Hierarchical) nad metodą opartą na gęstości (DBSCAN) dla analizowanego zbioru danych kart kredytowych.

K-Means i klasteryzacja hierarchiczna osiągnęły niemal identyczne wartości Silhouette Score (odpowiednio 0.3621 i 0.3630), co świadczy o stabilności struktury czterech klastrów – niezależnie od zastosowanego algorytmu. Wartości w przedziale 0.25–0.50 są typowe dla wielowymiarowych danych finansowych i wskazują na obecność struktury klastrowej przy jednoczesnym częściowym nakładaniu się grup. Przewaga K-Means w indeksie Daviesa-Bouldina (1.1591 vs 1.1820) oraz znacznie krótszy czas obliczeń czynią go metodą preferowaną dla tego zbioru danych.

DBSCAN, jako jedyna metoda automatycznie wyznaczająca liczbę klastrów, wykrył jedynie 2 grupy (zamiast 4), osiągając najgorsze wyniki metryczne (Silhouette = 0.1472, DBI = 2.0035). Wynika to z faktu, że dane kart kredytowych nie posiadają wyraźnej struktury gęstościowej – klastry klientów różnią się ilościowo w zachowaniach, lecz nie tworzą izolowanych zagęszczeń w przestrzeni cech.

W kontekście tematu projektu – automatycznego wykrywania liczby klastrów – elbow method i silhouette score okazały się metodami najbardziej skutecznymi i spójnymi. Gap statistic dostarczyła dodatkowego potwierdzenia, jednak jej obliczeniowa złożoność jest istotnie wyższa. Ograniczeniem analizy jest wrażliwość DBSCAN na parametr ε – przy innych wartościach liczba wykrytych klastrów zmieniała się istotnie.

7. Wnioski

1. Spośród porównanych metod wyznaczania optymalnej liczby klastrów, elbow method i silhouette score zastosowane dla K-Means okazały się najbardziej skuteczne – spójnie wskazywały $k=4$ jako optymalne.
2. Gap statistic dostarczyła dodatkowego potwierdzenia wyboru k , jednak jej obliczeniowa złożoność jest istotnie wyższa niż pozostałych metod.
3. DBSCAN automatycznie wykrył jedynie 2 klastry i osiągnął najgorsze wyniki metryczne, co wskazuje na ograniczoną przydatność tej metody dla danych finansowych bez wyraźnej struktury gęstościowej.
4. K-Means i klasteryzacja hierarchiczna dały niemal identyczne wyniki (różnica Silhouette < 0.001), co potwierdza stabilność wyznaczonego podziału na 4 segmenty klientów.
5. Zidentyfikowane klastry posiadają czytelną interpretację biznesową: *Aktywni na raty*, *Użytkownicy gotówki*, *Premium Shoppers* oraz *Jednorazowi kupujący*.
6. Analiza Feature Importance wykazała, że typ zakupów (jednorazowe vs ratalne) jest kluczowym czynnikiem różnicującym segmenty klientów.
7. Kierunkiem dalszych badań mogłoby być zastosowanie HDBSCAN lub bardziej agresywna selekcja cech przed klasteryzacją.

Oświadczenie o reprodukowalności

Projekt jest możliwy do odtworzenia w repozytorium GitHub: <https://github.com/bruno12303/Eksploracja%5Fi%5Fwizualizacja%5Fdanych%5Fprojekt>

References

- [1] J. Han, M. Kamber, J. Pei, *Data Mining: Concepts and Techniques*, Morgan Kaufmann, 2011.
- [2] G. James, D. Witten, T. Hastie, R. Tibshirani, *An Introduction to Statistical Learning*, Springer, 2021.
- [3] T. Hastie, R. Tibshirani, J. Friedman, *The Elements of Statistical Learning*, Springer, 2009.
- [4] R. Tibshirani, G. Walther, T. Hastie, *Estimating the number of clusters in a data set via the gap statistic*, Journal of the Royal Statistical Society, Series B, 63(2):411–423, 2001.
- [5] P. J. Rousseeuw, *Silhouettes: a graphical aid to the interpretation and validation of cluster analysis*, Journal of Computational and Applied Mathematics, 20:53–65, 1987.

- [6] D. L. Davies, D. W. Bouldin, *A cluster separation measure*, IEEE Transactions on Pattern Analysis and Machine Intelligence, 1(2):224–227, 1979.
- [7] C. Molnar, *Interpretable Machine Learning*, 2022.
- [8] A. Bhasin, *Credit Card Dataset for Clustering*, Kaggle, <https://www.kaggle.com/datasets/arjunbhasin2013/ccdata>, 2018.